

Statistique Descriptive

Population => désigne humain, objet, des villes
entreprise, pays.

Caractère statistique \Rightarrow désigne une grandeur ou un attribut

Modalité \Rightarrow des valeurs ou des réponses

par exemple ε $\left\{ \begin{array}{l} \text{Renault, Ford, Peugeot} \\ 15; 11,25; 3 \end{array} \right\} \left\{ \begin{array}{l} \text{Marque} \\ \text{des voitures} \end{array} \right\}$
 $\left\{ \begin{array}{l} 15; 11,25; 3 \end{array} \right\} \left\{ \begin{array}{l} \text{note des} \\ \text{étudiant} \end{array} \right\}$

Type de caractère \Rightarrow caractère qualitatif

Caractère quantitatif

discret

(nombre entier)

continue

(des intervalle $[[, []$)

Représentation des données

Série statistique 2 1 0 3 2 2 4 4

Tableaux statistiques


marcador x_i	0	1	2
n_i	1	1	2
\tilde{n}_i	1	$1+1=2$	$2+2=4$
f_i	$1/4$	$1/4$	$2/4$
\hat{f}_i	$1/4$	$2/4$	$4/4=1$

$\Rightarrow (n)$

Représentation graphique

* Caractère qualitatif


- Secteurs circulaire
 - Diagramme d'orgue



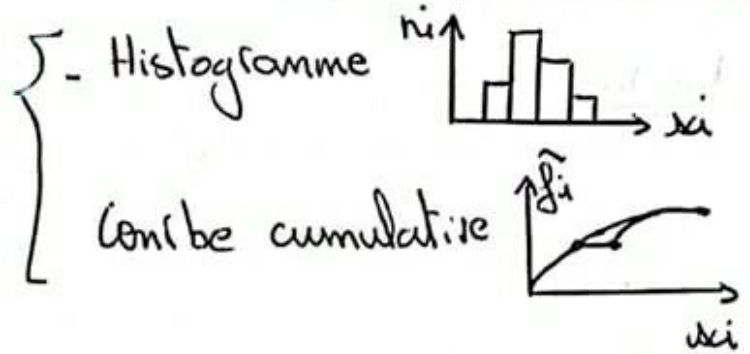
$$D_i = f_i \times 360$$

* Caractère quantitatif discret

- Diagramme de bâton
 - Courbe cumulative
 courbe en escalier



variable quantitative
continue



Fonction de répartition (cas discret)

$$f(x) = \begin{cases} 0 & \text{si } x < x(1) \\ f_{cum} & \text{si } x(i) \leq x < x(i+1) \\ \vdots & \text{pour } i = 1, \dots, n-1 \\ \downarrow & \\ & \text{si } x \geq x(n) \end{cases}$$

Fonction de répartition (cas continu)

$$f(x) = \begin{cases} 0 & \text{si } x < a_i \\ \underbrace{f_{i-1}}_{\downarrow} + \frac{x - a_i}{\text{amplitude}} \underbrace{f_i}_{\downarrow} & \text{si } a_i \leq x < a_{i+1} \\ & \text{si } x \geq a_{i+1} \end{cases}$$


fréquence cumulée de classe précédente fréquence de classe

cas continue

$$Me = a_i + \frac{\frac{n}{2} - h_{i-1 \text{ cum}}}{h_i} (a_{i+1} - a_i)$$

La classe médiane $[a_i, a_{i+1}[$

graphiquement



Les quantiles

cas discret

$$q_\alpha = \begin{cases} \frac{x_{n\alpha} + x_{n\alpha+1}}{2} & n\alpha \text{ entier} \\ x_{[n\alpha]+1} & n\alpha \neq N \end{cases}$$

cas continue

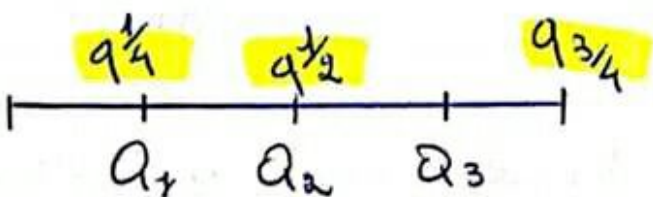
La classe $[a_i, a_{i+1}[$

$$q_\alpha = a_i + \frac{(a_{i+1} - a_i)}{h_i} (n\alpha - h_{i-1 \text{ cum}})$$

Remarque

* Pour $\alpha = \frac{1}{2}$ $q_\alpha = \text{Mediane (Me)}$

* Les quartiles :



* Les déciles :

$D_1 = q_{1/10}$	$D_2 = q_{2/10}$
Jusqu'à	$D_9 = q_{9/10}$

* Les centiles :

$C_1 = q_{1/100}$	$C_2 = q_{2/100}$
Jusqu'à	$C_{99} = q_{99/100}$

Les moyennes

1. Moyenne arithmétique

$$\bar{X} = \frac{1}{n} \sum_{i=1}^p n_i x_i = \sum_{i=1}^p f_i x_i$$

$$\bar{X} = \frac{1}{n} \sum x_i \Rightarrow \text{donnée brute}$$

2. Moyenne géométrique (statistique discrète)

$$G = \sqrt[n]{\prod_{i=1}^p x_i^{n_i}} = \prod_{i=1}^p x_i^{f_i}$$

Moyenne harmonique (série discrète)

$$H = \frac{n}{\sum_{i=1}^p n_i \left(\frac{1}{x_i} \right)} = \frac{1}{\sum_{i=1}^p f_i \left(\frac{1}{x_i} \right)}$$

4- Moyenne quadratique (" ")

$$Q = \sqrt{\frac{1}{n} \sum n_i x_i^2} = \sqrt{\sum_{i=1}^p f_i x_i^2}$$

Remarque

=> Dans les séries statistiques continues on remplace x_i par le centre de la classe

$$C_i = \frac{a_i + a_{i+1}}{2}$$

=> toujours on a $H < G < \bar{X} < Q$

=> Si $H = G = \bar{X} = Q$ le nombre de modalités $p=1$ ou $(x_i)_{1 \leq i \leq n}$ sont égales

Paramètre de dispersion

a. Étendue

$$E = x_{\max} - x_{\min}$$

b. écart absolu moyen

$$E_m = \frac{1}{n} \sum_{i=1}^p n_i |x_i - \bar{x}|$$

c. La variance

$$V(x) = \sigma^2 = \frac{1}{n} \sum_{i=1}^p n_i (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^p n_i x_i^2 - \bar{x}^2$$

d. Écart type

$$\sigma = \sqrt{V(x)}$$

e. Écart interquartile

est donnée par $I_\alpha = q_{1-\alpha} - q_\alpha$

L'intervalle interquantile $[q_\alpha, q_{1-\alpha}]$

contient $100(1-2\alpha)\%$ des valeurs centrale

\Rightarrow L'écart interquantile $q_{3/4} - q_{1/4}$

contient **50%** des valeurs centrale

\Rightarrow L'écart interdécile contient **80%** des valeurs centrale.

$$q_{9/10} - q_{1/10}$$

Coefficient de variation

$$CV = \frac{\sigma}{\bar{X}}$$

Paramètre de Forme

a. coefficient d'asymétrie

=> Distribution symétrique $M_0 = M_e = \bar{X}$

=> " asymétrique à droite $\bar{X} < M_e < M_0$

=> " " à gauche $M_0 < M_e < \bar{X}$


=> Coefficient d'asymétrie de Fisher :

$$\gamma = \frac{\mu_3(X)}{\sigma^3(X)}$$


On a $\mu_3(X) = \frac{1}{n} \sum n_i (x_i - \bar{X})^3$ 3^{es} moment centre d'ordre 3

=> Si $\gamma > 0$ distribution asymétrique à gauche

=> Si $\gamma = 0$ distribution symétrique :



(9)




Asymétrie positive

Normal (no skew)

\Rightarrow Si $\gamma < 0$ distribution asymétrique à droite

Asymétrie négative \Rightarrow



b. coefficient d'aplatissement

\Rightarrow mesure de la hauteur d'une distribution

\Rightarrow Coefficient d'aplatissement de Pearson


$$K = \frac{\mu_4(X)}{\sigma^4(X)}$$

$$\mu_4(X) = \frac{1}{n} \sum n_i (x_i - \bar{x})^4 \leftarrow \text{moment centré d'ordre 4}$$

\Rightarrow Si $K > 3$ distribution (forme pointue) au niveau de la moyenne, extrémité longue et étendue.

\Rightarrow Si $K < 3$ distribution plus aplatie, extrémité courte et resserrées

Remarque Dans le cas statistique continue on remplace n_i par f_i



- distribution leptocurtique
- distribution normale (mésokurtique)
- distribution platycurtique

Changement de Variable

Soit X et Y deux variable statistique et a et b deux nombre réels

$$X = ay + b \quad \bar{X} = a\bar{y} + b \quad \sigma_x^2 = a^2 \sigma_y^2$$

a = amplitude de la classe

b = milieu de la classe centrale

(Si le nombre de classe est paire, prendre la classe ayant le plus grand effectif)

On obtient :

$$y_i = \frac{x_i - b}{a}$$

$$\bar{y} = \frac{1}{n} \sum n_i y_i$$

$$\sigma_y^2 = \frac{1}{n} \sum n_i y_i^2 - \bar{y}^2$$

$$\sigma_y^2 = \frac{1}{n} \sum n_i (y_i - \bar{y})^2$$

$$\text{L'ampétude} = \frac{x_{\max} - x_{\min}}{\text{nombre de classe}}$$

Statistique Double

Tableau de contingence

X \ Y	[0,5[[5,10[[10,15[[15,20[n_i
0	2	0	3	0	5
1	0	1	2	3	6
2	0	0	1	1	2
n_j	2	1	6	4	13

$n_i \Rightarrow$ total d'une ligne i (effectif marginal)

$n_j \Rightarrow$ " " " " " "

Distribution marginale

X	0	1	2		X	[0,5[[5,10[[10,15[
$n_{i\cdot}$	5	6	2		$n_{\cdot j}$	2	1	6
$f_{i\cdot}$	$5/13$	$6/13$	$2/13$		$f_{\cdot j}$	$2/13$	$1/13$	$6/13$

$$f_{i\cdot} = \frac{n_{i\cdot}}{n}$$

$$f_{\cdot j} = \frac{n_{\cdot j}}{n}$$

Les moyennes de \bar{X} et \bar{Y}

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n n_{i1} x_i = \sum_{i=1}^n f_i \cdot x_i$$

$$\bar{Y} = \frac{1}{n} \sum_{j=1}^n n_{j1} y_j$$

$$= \sum_{j=1}^n f_{\cdot j} y_j$$

Calcul des fréquences

$$* f_{xx} = p_{23} = \frac{n_{23}}{n} \Rightarrow n_{ij}$$

$\downarrow \quad \downarrow$
 ligne colonne

$$* f_{X=A/Y=B} = \frac{n_{AB}}{n_{\cdot B}}$$

\nwarrow le rang de X
 \swarrow le rang de Y
 $\underbrace{n_{\cdot B}}$
 \downarrow
 la somme de $X=B$

Distr. bution Conditionnelle

On nous donne par exemple une distribution de $X/Y = 3$

\Rightarrow on suit l'ordre de X et on prend les $n_{.j}$ de X

\Rightarrow pour les f_i on divise par la somme de la colonne X .

calculer une moyenne dans la distribution Conditionnelle

$$(\bar{X}/Y)_A = \sum_{i=1}^n (X/Y)_{=A} \times f(X/Y)_{=A}$$

L'indépendance

$X \perp Y \Rightarrow f_{ij} = f_i \times f_{.j} \Rightarrow$ ils sont indépendants

$f_{ij} \neq f_i \times f_{.j} \Rightarrow$ ils ne sont pas indépendants

\Rightarrow Dans une distribution conditionnelle

$\bar{X} = (\bar{X}/Y) = \text{cst} \Rightarrow$ indépendant

La covariance entre X et Y (cov(X,Y))

Série brute

$$\begin{aligned}\text{cov}(X,Y) &= \sigma_{xy} \\ &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})\end{aligned}$$

$$\text{cov}(X,Y) = \left(\frac{1}{n} \sum x_i y_i \right) - (\bar{x} \bar{y})$$


Série groupée

$$\begin{aligned}\text{Cov}(X,Y) &= \sigma_{xy} \\ &= \frac{1}{n} \sum_j \sum_i n_{ij} (x_i - \bar{x})(y_j - \bar{y})\end{aligned}$$

$$\text{cov}(X,Y) = \left(\frac{1}{n} \sum_j \sum_i n_{ij} x_i y_j \right) - (\bar{x} \bar{y})$$

$\sum_j \sum_i n_{ij} x_i y_j$

x_i	$X \backslash Y$	30	50
195	$[20, 20[$	2	1
217	$[206, 217]$	0	1



$$\Rightarrow x_i \times 2 \times 30 = \sum_j \sum_i n_{ij} y_j$$

correlation

$$r_{xy} = \rho_{xy} = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$$

$$\text{Var}(x) = \frac{1}{n} \sum x_i^2 n_i - (\bar{x})^2$$

$$\text{Var}(y) = \frac{1}{n} \sum n_i y_i^2 - (\bar{y})^2$$

$$\sigma_x = \sqrt{\text{Var}(x)}$$

$$\sigma_y = \sqrt{\text{Var}(y)}$$

Si $\rho_{xy} \begin{cases} \approx 0 & \Rightarrow \text{faible correlation} \\ = 0 & \Rightarrow \text{pas de correlation} \\ = \pm 1 & \Rightarrow \text{une forte correlation} \end{cases}$

Droite de Régression de Y en X :

$$\text{On a } Y = aX + b$$

$$\begin{cases} a = \frac{\text{cov}(x, y)}{\text{Var}(x)} \\ b = \bar{y} - a\bar{x} \end{cases} \Rightarrow Y = aX + b$$

la correlation

$$r_{xy} = \rho_{xy} = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$$

$$\text{Var}(x) = \frac{1}{n} \sum x_i^2 n_i - (\bar{x})^2$$

$$\text{Var}(y) = \frac{1}{n} \sum n_i y_i^2 - (\bar{y})^2$$

$$\sigma_x = \sqrt{\text{Var}(x)}$$

$$\sigma_y = \sqrt{\text{Var}(y)}$$

Si $\rho_{xy} \begin{cases} \approx 0 & \Rightarrow \text{faible correlation} \\ = 0 & \Rightarrow \text{pas de correlation} \\ = \pm 1 & \Rightarrow \text{une forte correlation} \end{cases}$

Droite de Regression de Y en X :

$$\text{On a } Y = aX + b$$

$$\begin{cases} a = \frac{\text{cov}(x, y)}{\text{Var}(x)} \\ b = \bar{y} - a\bar{x} \end{cases} \Rightarrow Y = aX + b$$

Probabilité

=> L'univers, on le note par " Ω "
 ou l'espace fondamentale " Ω "

exp * dans le cas du lancer d'un dé cubique $\Omega = \{1, 2, 3, 4, 5, 6\}$

* dans le cas du lancer d'une pièce de monnaie $\Omega = \{\text{pile}, \text{Face}\}$

=> Le cardinal, on le note par $|\Omega|$

Notion d'événement

Notion	Vocabulaire proba
Ω	Événement certain
\emptyset	" impossible
ω	" élémentaire
$\omega \in A$	ω réalise A
$A \subset B$	A implique B
$A \cup B$	A ou B
\bar{A}	Événement contraire de A
$A \cap B = \emptyset$	A et B sont incompatibles

Opération logique sur les ensembles

* En terme d'événement $A \cup B$ est réalisé

si au moins un des deux événements A ou B sont réalisés

* En terme d'événement $A \cap B$ est réalisé lorsque simultanément les deux événements A et B sont réalisés

Calcul des probabilités

* L'événement \bar{A} :

$$P(\bar{A}) = 1 - P(A)$$

* L'événement $A \cup B$:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

\Rightarrow Si A et B sont incompatibles

$$P(A \cup B) = P(A) + P(B)$$

* La probabilité $P(A)$:

$$P(A) = \frac{\text{cas favorable}}{\text{cas possible}} = \frac{|A|}{|\Omega|}$$

$$* P(A) + P(\bar{A}) = 1$$

Tirage de (p) element parmis (n)

et $\rightarrow \times$

ou $\rightarrow +$

Simultané

L'ordre n'est pas
important

Combinaison C_n^p

$$C_n^p = \frac{n!}{(n-p)! p!}$$

Successive

L'ordre est
important

Arrangement A_n^p

$$A_n^p = \frac{n!}{(n-p)!}$$

Probabilité conditionnelle

$$* P(A|B) = \frac{P(A \cap B)}{P(B)} \quad \left. \vphantom{\frac{P(A \cap B)}{P(B)}} \right\} \begin{array}{l} \text{probabilité de A} \\ \text{sachant B} \end{array}$$

$$* P(A \cap B) = P(A|B)P(B)$$

$$* P(B|A) = \frac{P(A \cap B)}{P(A)}$$

$$P(\bar{A} \setminus \bar{B}) = \frac{P(\bar{A} \cap \bar{B})}{P(\bar{B})} = \frac{P(\overline{A \cup B})}{P(\bar{B})}$$

$$= \frac{1 - P(A \cup B)}{1 - P(B)}$$

parmi = sachant

Formule de Bayes

$$P(A \setminus B) = \frac{P(B \setminus A | P(A))}{P(B \setminus A | P(A)) + P(B \setminus \bar{A} | P(\bar{A}))}$$

Formule der probabilité totale

$$P(A \cap \bar{B}) = P(A) - P(A \cap B)$$